HAFTA 8

Veri Bilimi I

Veri seti, keşifsel veri analizi (EDA) ve özellik mühendisliği

Bera Ergin · s29315 · PJAIT · Türksat stajı

Bu haftanın amacı

1

Veri

UCI Student Performance indirildi; sha256 sağlamaları CHECKSUMS.txt içinde, her çalıştırmada doğrulanıyor.

2

EDA

6 grafik, eda_summary.json ve TR/EN iki notebook. Tüm sayılar koddan hesaplanıyor.

3

Özellikler

EARLY ve MIDTERM özellik setleri; fit edilmemiş ön işleme hattı.

Bu hafta model eğitilmedi. Model karşılaştırması, çapraz doğrulama ve SHAP Hafta 9'da.

Veri seti

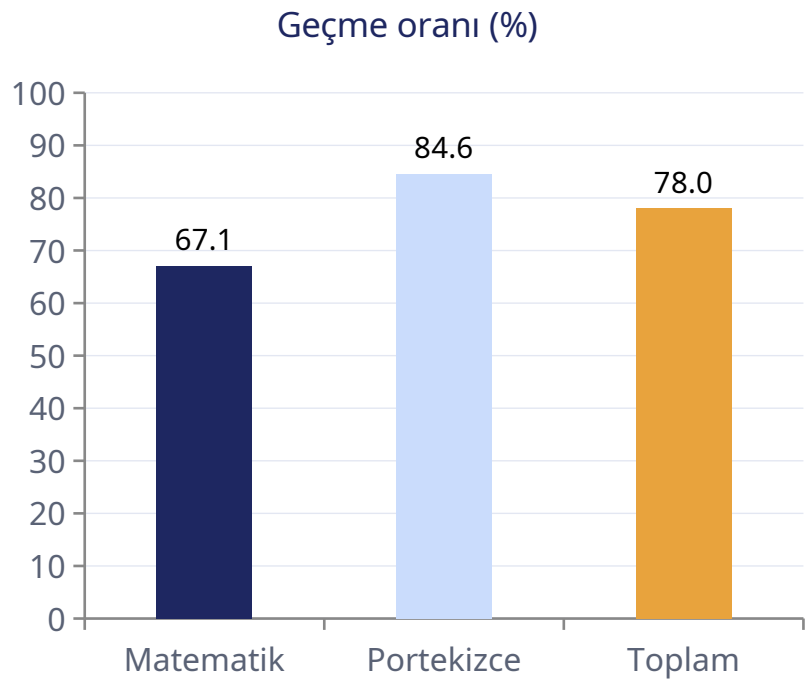
1044	395 / 649	0	366
toplam kayıt	Matematik / Portekizce	eksik değer	iki derste ortak öğrenci

Kaynak: Cortez & Silva (2008), UCI Machine Learning Repository, CC BY 4.0. İki Portekiz lisesi; not ölçeği 0–20 (G1, G2 dönem içi; G3 final). Ortak öğrenciler student_key ile işaretlendi.

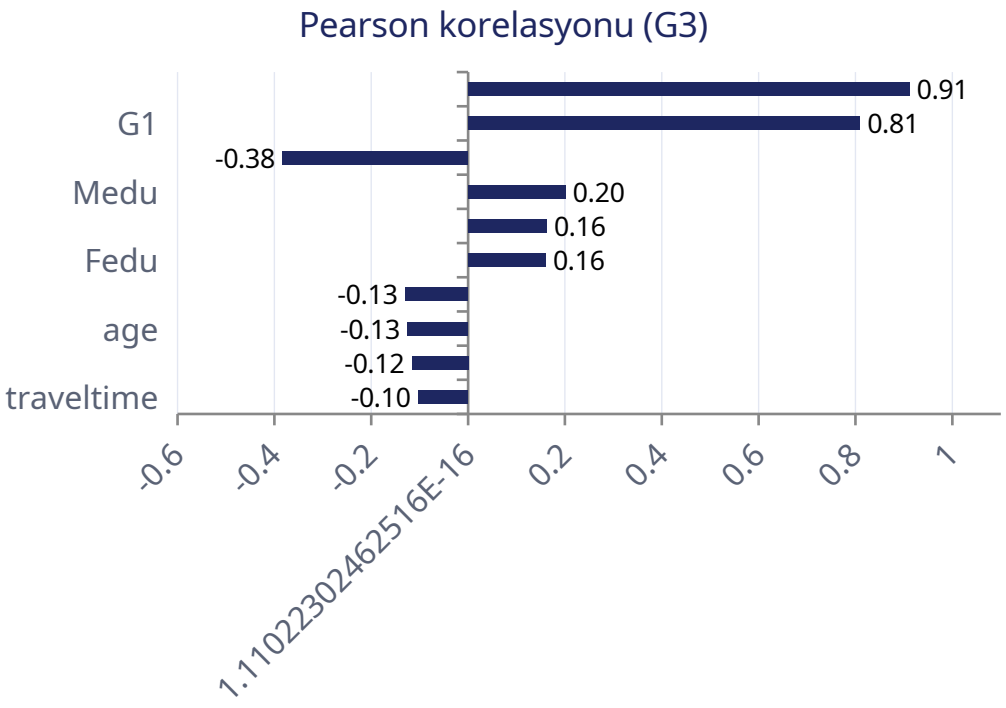
Hedef tanımı: at_risk = G3 < 10

```
G3 < 10   ⇔   G3 × 5 < 50 = PASS_GRADE
```

Eşik, sistemimizdeki geçme notuyla (PASS_GRADE=50) birebir aynı. Risk oranı matematikte %32,9, Portekizcede %15,4; toplamda 230 öğrenci (%22,0).



G3 ile en güçlü 10 ilişki



- Not dışı en güçlü sinyal: geçmiş başarısızlık (failures, −0,38).
- Anne/baba eğitimi ve çalışma süresi: zayıf pozitif (0,16–0,20).
- Alkol, yaş ve yol süresi: zayıf negatif (−0,10 ile −0,13 arası).

Sızıntı riski: G1 ve G2

0,91

G2 – G3

0,81

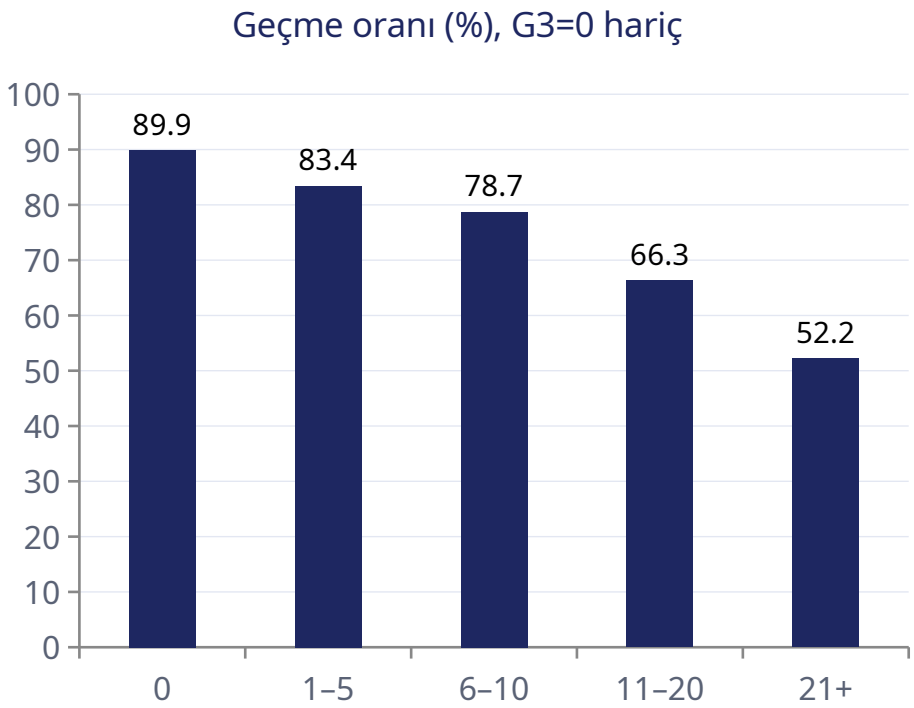
G1 – G3

G2 ile G3'ü tahmin etmek neredeyse sonucu tekrar etmek olur. Bu nedenle iki ayrı özellik seti tanımlandı:

EARLY	G1 ve G2 yok — dönem başı erken uyarı
MIDTERM	G1 var, G2 yok — dönem ortası

G3 hiçbir sette yer almıyor; testlerle kontrol ediliyor.

Devamsızlık: düzeltilmiş bulgu



- 53 G3=0 kaydının tamamında devamsızlık 0; bu kayıtlar ilk korelasyonu bastırıyordu (Pearson −0,05).
- G3=0 hariç: Pearson −0,22, Spearman −0,24. Devamsızlık arttıkça geçme oranı düzenli düşüyor.
- 21+ grubunun yine de yarısı geçiyor (n=23): devamsızlık tek başına karar verdirmez.
- Sistemde mazeretsiz devamsızlık kullanılmalı.

Hata kaydı 1: devamsızlık analizi

Alan	Açıklama
Belirti	İlk EDA'da devamsızlık G3 ile en güçlü 10 ilişkiye girmedi; "zayıf gösterge" sonucu çıkarıldı.
Kök neden	53 G3=0 kaydının tamamı 0 devamsızlık diliminde. Bu kayıtlar (olası sınava girmeme/ayrılma) ilişkiyi bastırıyordu.
Düzeltme	Korelasyon ve dilim analizi G3=0 dahil/hariç ayrı hesaplandı (notebook, bölüm f).
Durum	Doğrulandı: G3=0 hariç Pearson −0,22, dilimlerde geçme oranı %89,9'dan %52,2'ye düşüyor.

Veri kalitesi ve dikkat noktaları

Konu	Değer	Karar
G3 = 0	`53 kayıt (%5,1)`	Silinmedi; g3_zero bayrağı eklendi. Hepsinde devamsızlık 0; nedeni (sınava girmeme, ayrılma) belirtilmiyor. İlişki analizlerinde ayrıca hariç tutularak bakılmalı.
Ortak öğrenci	`366`	Literatürde 382 bildiriliyor; eşleştirme sütunları farklı. Hafta 9'da GroupKFold grubu olarak kullanılacak.
Eksik değer	`0`	Doldurma (imputation) gerekmedi.

Özellik mühendisliği

Türetilmiş özellikler

- parent_edu_max — anne/baba eğitiminin büyüğü
- alcohol_total — Dalc + Walc
- support_any — okul veya aile desteği
- has_failures — geçmiş başarısızlık var mı
- absences_log1p, absence_bucket

Ön işleme hattı

- İkili kategoriler 0/1
- Nominal kategoriler one-hot (handle_unknown="ignore")
- Sıralı sütunlar olduğu gibi
- Hat fit edilmemiş döner; Hafta 9'da CV katmanları içinde fit edilecek (sızıntı yok)

Sistemimizle eşleme

UCI özelliği	Bizim şemamız	Durum
`G1 / G2`	Not ortalaması ÷ 5	**Türetilebilir**
`absences`	Devamsızlık kayıtları (mazeret ayrımıyla)	**Var**
`failures`	—	**Yok**
`studytime, Medu/Fedu, destek`	—	**Yok**

Sonuç: Sistemimiz yalnızca not ve devamsızlık tutuyor. Bu yüzden Hafta 10'daki risk göstergesi bir karar değil, gerekçesiyle gösterilen bir dikkat bayrağı olacak.

Doğrulama

233 passed

1 warning (henüz incelenmedi)

```
python -m data_science.download
python -m data_science.eda
python -m data_science.features
```

- Testler ağ kullanmıyor; 30 satırlık sentetik fixture CSV ile çalışıyor.
- İki notebook nbconvert ile baştan hatasız çalıştı.
- Kontroller: hedef eşiği (G3=9 → 1, G3=10 → 0), setlerde G1/G2/G3 yokluğu, NaN üretmeyen dönüşüm, bilinmeyen kategori.
- Uygulama kodu, mock veri ve eval bu haftanın kapsamı dışında tutuldu.

Notebook'lar

`01_uci_eda.ipynb`	Türkçe anlatım
`01_uci_eda_eng.ipynb`	İngilizce anlatım
`notebooks/html/`	GitHub dışında görüntüleme için HTML

Notebook'lar çıktılarıyla birlikte kaydedildi ve baştan çalıştırıldı. Mantık data_science paketinden import ediliyor; kod kopyalanmadı. Sayılar markdown'a elle yazılmadı, hücre çıktılarından okunuyor.

a. Veri seti
b. Hedef tanımı
c. G3 dağılımı
d. Korelasyonlar
e. Sızıntı
f. Devamsızlık analizi
g. Özellik setleri
h. Sonuç

UCI'ın sınırları ve karar

UCI'ın verdiği: genel risk sinyali

- Erken notlar finali güçlü yansıtıyor (G1–G3 r = 0,81)
- Geçmiş başarısızlık: not dışı en güçlü sinyal (r = −0,38)
- Devamsızlık: G3=0 hariç anlamlı ama tek başına belirleyici değil

UCI'ın veremediği: bağlam

- Tek öğretim yılı, iki ders, iki okul
- Ders, öğretmen veya sınav bağlamı yok
- Sınav tarihi ve sırası yok; gerçek erken uyarı kurulamaz
- ~678 tekil öğrenci, ~230 riskli: küçük örneklem

Karar: UCI genel (temel) model olarak kalır; bağlam hipotezi daha büyük ve zamansal bir veri setinde test edilir.

Hipotez: risk dersin bağlamına göre değişir

Örnek: Bir öğretmenin dönem sonu sınavı geçen yıl diğerlerinden zordu ve birçok öğrencinin notu düştü. İlk iki sınavı sınırda olan bir öğrencinin bu derste riski, aynı notlarla başka bir dersteki öğrenciden daha yüksektir.

Hafta 8
UCI: genel model temeli

›

Hafta 9
OULAD: ders geçmişi özellikleri

›

Hafta 10
Kıyas: genel vs ders geçmişli

›

Hafta 11
Tarif sisteme: risk sekmesi

İlkeler: Risk gerekçeli bir dikkat bayrağıdır, karar değildir. Sistemde sosyokültürel özellik kullanılmaz; yalnızca not, mazeretsiz devamsızlık ve ders bağlamı. OULAD'dan sisteme veri veya model taşınmaz, yalnızca doğrulanmış özellik tarifi taşınır.

Açık konular ve Hafta 9

Açık konular

- Hata kaydı 1 (devamsızlık analizi): doğrulandı.
- Notebook görsellerinde alternatif metin eksik (6 görsel).
- Hafta 6 hata 4 (pivotta sessiz ortalama): doğrulanacak.
- Hafta 7 eval: m5 (nedensellik tahmini) ve c4 (73,98 → "73") açık.
- pytest uyarısı incelenecek.

Hafta 9 — OULAD

- Daha büyük ve zamansal veri: OULAD (Open University)
- Ders geçmişi özellikleri: notun dersin geçmiş ortalamasına göre konumu
- Zamansal bölme: 2013 dönemleriyle eğitim, 2014 ile test
- 02 numaralı notebook ile sunum