HAFTA 9

Veri Bilimi II

OULAD: kesim günü, ders geçmişi özellikleri ve zamansal bölme

Bera Ergin · s29315 · PJAIT · Türksat stajı

Bu haftanın amacı

1

Veri

OULAD indirildi, sha256 sabitlendi. 10,6 milyon satırlık tıklama tablosu parçalı okunup günlük özete indirildi.

2

Özellikler

60. gün kesimi, at_risk hedefi, genel ve ders geçmişi özellikleri, sızıntısız zamansal bölme.

3

Notebook

02_oulad_eda (TR/EN) ve HTML. Sayılar yalnızca hücre çıktılarından.

Bu hafta model eğitilmedi. Genel model ile ders geçmişli modelin karşılaştırması Hafta 10'da.

Neden OULAD?

32.593	7 / 22	206	10.655.280
kayıt (öğrenci × sunum)	modül / sunum	ödev ve sınav	tıklama satırı

Kaynak: Kuzilek, Hlosta & Zdrahal (2017), Open University Learning Analytics Dataset, UCI (id 349), CC BY 4.0. UCI'da olmayan iki şey burada var: aynı dersin birden çok dönemi (2013B, 2013J, 2014B, 2014J) ve tarihli ödev ile etkinlik kayıtları. Bu, ders bağlamı hipotezini test etmeyi ve gerçek bir erken uyarı anı tanımlamayı mümkün kılıyor.

Veri ve doğrulama

Tablo	Satır	Not
studentInfo	32.593	Anahtar tekil; imd_band 1.111 eksik
studentRegistration	32.593	date_unregistration 22.521 boş (kayıt sürüyor)
assessments	206	date 11 eksik
studentAssessment	173.912	score 173 eksik
vle / courses	6.364 / 22	—
studentVle	10.655.280	Parçalı okundu

sha256

Arşiv özeti sabitlendi; her çalıştırmada doğrulanıyor.

Parçalı özet

Ham ve günlük özette satır (10.655.280) ve tıklama toplamı (39.605.099) birebir aynı.

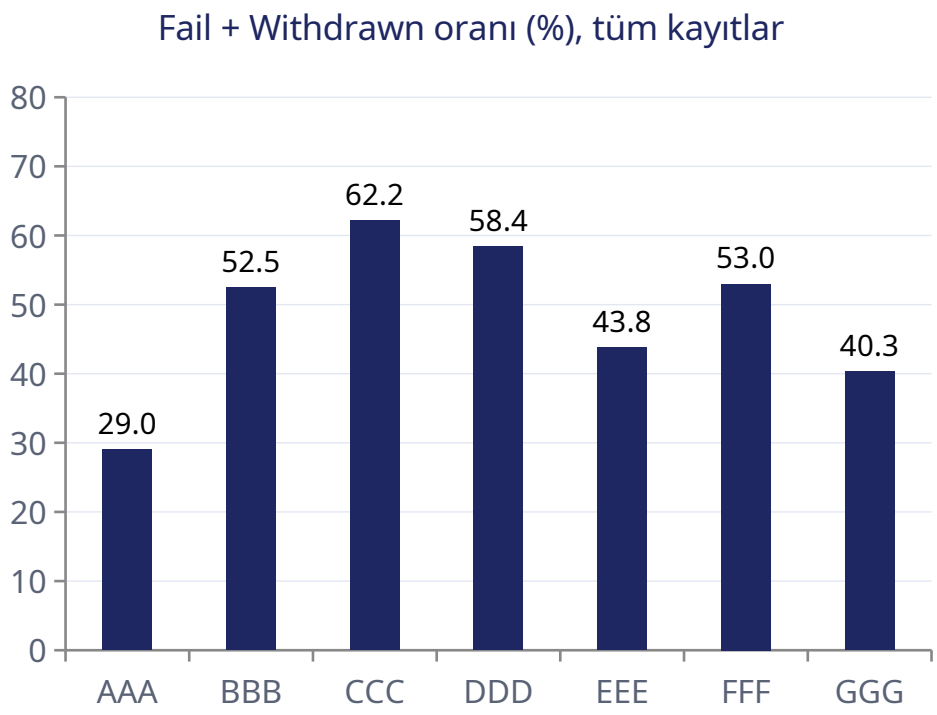
Erken uyarı anı ve hedef

```
at_risk = final_result ∈ {Fail, Withdrawn}
```

- Kesim günü: CUTOFF_DAY = 60 (ayarlanabilir).
- Yalnızca tarihi ve teslimi 60. güne kadar olan ödevler; final sınavı hariç.
- Tıklamalar 60. güne kadar.
- 60. günden önce kaydını silenler örneklemden çıkarıldı; sonra silenler kaldı ve at_risk = 1.

32.593	tüm kayıt
−6.190	kesimden önce ayrılan
26.403	örneklem

Ders bağlamı: modüller arası fark büyük



- Modüller arasında oran %29,0 (AAA) ile %62,2 (CCC) arasında.
- Aynı modülün dönemleri birbirine yakın: dönemler arası fark en fazla 6,5 puan (EEE).
- Örneklemde (60. gün sonrası) en düşük AAA 2013J %23,4, en yüksek DDD 2013B %52,6.
- Betimsel bulgu: bir dersin geçmiş risk oranı bilgi taşıyor gibi görünüyor. Kanıt Hafta 10'daki karşılaştırmada.

Ders geçmişi özellikleri

Sunum P için geçmiş = aynı modülün YALNIZCA P'den kesinlikle önceki sunumları. P ve sonrası hiçbir özelliğe girmez.

Özellik	Tanım
`hist_slot_mean`	Aynı ödev sırasının (modül, tür, sıra no) geçmiş ortalama notu: ödevin zorluğu
`hist_slot_submit_rate`	Aynı ödev sırasının geçmiş teslim oranı
`score_vs_hist`	Öğrencinin notu − hist_slot_mean (öğrenci ortalaması)
`hist_module_risk_rate`	Önceki sunumların at_risk oranı (aynı örneklem tanımıyla)
`has_history`	Önceki sunum yoksa 0; geçmiş sütunları NaN kalır, doldurulmaz

Genel özellikler (60. güne kadar)

Ödevler

- Beklenen, teslim edilen, teslim edilmeyen sayısı
- Ağırlıklı ve ağırlıksız ortalama not
- Ortalama gecikme (teslim − son tarih)
- is_banked satır sayısı (satırlar silinmedi)

Etkinlik (VLE)

- Toplam tıklama, aktif gün sayısı
- Son etkinlikten kesime kalan gün
- En sık 5 etkinlik türünde tıklama
- date_registration

Kullanılmayanlar: sosyokültürel sütunlar (cinsiyet, bölge, eğitim, imd_band, yaş, engellilik), num_of_prev_attempts, studied_credits. Toplam 26 sütun.

Zamansal bölme

Bölüm	Sunumlar	Satır	at_risk	Geçmişi var
`history`	2013B	3.927	%46,7	%0,0
`train`	2013J + 2014B	13.639	%42,6	%74,1
`test`	2014J	8.837	%38,3	%100,0

- 2013B yalnızca geçmiş kaynağı; eğitime ve teste girmiyor.
- Test %100 geçmişli: 2014J'nin her modülde önceki sunumu var.
- Train'deki geçmişsiz satırlar: AAA, EEE, GGG'nin ilk sunumu (2013J) ve CCC 2014B; bu modüllerde 2013B yok.

Eksik değerler tutarlı

Sütun	Eksik	Açıklama
`hist_module_risk_rate`	7.465	= history 3.927 + geçmişsiz train 3.538. Beklenen.
`hist_slot_mean`	8.952	7.465 + 1.487 (GGG, bkz. veri notu 1)
`score_vs_hist`	10.046	Geçmiş ve öğrenci notu birlikte gerekli
`score_mean`	3.995	60. güne kadar notlu teslim yok
`score_weighted_mean`	4.172	score_mean + 177 (BBB, bkz. veri notu 2)
`vle_days_to_cutoff`	564	60. güne kadar hiç etkinlik yok
`date_registration`	7	Kaynak tabloda eksik

Veri notları (hata değil)

1 · GGG 2014B / 2014J

1.487 satırın tamamında n_expected = 0 (790 + 697). Bu iki sunumda 60. güne kadar notlu ödev yok; eşleşecek ödev sırası da yok.

Sonuç: GGG'de kesim anında yalnızca etkinlik sinyali var.

2 · BBB 2014J

60. güne kadar ağırlığı 0 olan bir TMA var. Yalnızca onu teslim eden 177 öğrencide ağırlıklı ortalama tanımsız.

Sonuç: NaN doğru; ağırlıksız ortalama mevcut.

Hata kaydı 1: test ortamı

Alan	Açıklama
Belirti	pytest toplama aşamasında durdu: ModuleNotFoundError: sklearn. Hafta 8 klasöründe de aynı hata.
Kök neden	Tüm haftaların kullandığı ortak sanal ortamda scikit-learn kurulu değildi. Kod kaynaklı değil.
Düzeltme	Ortak ortamda pip install -r requirements.txt.
Durum	Doğrulandı: 237 passed (9a sonrası), 243 passed (9b sonrası).

Sistemimizle eşleme

OULAD özelliği	Bizim karşılığımız	Durum
`score_mean`	Not ortalaması	**Var**
`vle_* (etkinlik)`	Mazeretsiz devamsızlık (yaklaşık)	**Yaklaşık**
`n_unsubmitted`	Girilmeyen sınav	**Doğrulanacak**
`delay_mean`	—	**Yok**
`hist_*`	Geçmiş dönem notları	**Sentetik (H10)**
`Sosyokültürel`	—	**Kullanılmaz**

Sistemde geçmiş dönem verisi yok. Hafta 10'da mock veriye dokunmadan ayrı bir sentetik okul geçmişi üretilecek. Bu yalnızca "sistem çalışıyor" gösterimidir; hipotezin kanıtı OULAD'dan gelir.

Notebook'lar

`02_oulad_eda.ipynb`	Türkçe anlatım
`02_oulad_eda_eng.ipynb`	İngilizce anlatım
`notebooks/html/`	HTML çıktılar

Notebook'lar baştan çalıştırılıp çıktılarıyla kaydedildi. Markdown'da sayı yok; her grafiğin altında açıklama hücresi var. Son hücre OZET değerleri validate çıktısıyla birebir aynı.

a. Amaç
b. Veri
c. Örneklem
d. Bölme
e. Ders bağlamı
f. Erken sinyaller
g. Veri notları
h. Okul sistemine köprü
i. Sınırlılıklar
j. Özet

Doğrulama

243 passed

1 warning (StarletteDeprecationWarning)

```
python -m data_science.oulad.download
python -m data_science.oulad.vle
python -m data_science.oulad.dataset
python -m data_science.oulad.validate --
features
```

- OULAD testleri ağ kullanmıyor; minik sahte tablolarla çalışıyor (9a: 4, 9b: 6 test).
- Kontroller: kesim sonrası ödev ve tıklama dışarıda, kayıt silme kuralı, geçmiş sızıntısı yok, has_history = 0 iken NaN, final sınavı hariç, parçalı özet = tek seferde özet.
- İki notebook nbconvert ile baştan çalıştı; hata hücresi 0.
- Uygulama kodu, mock veri ve eval kapsam dışında.

Açık konular ve Hafta 10

Açık konular

- Hata kaydı 1 (test ortamı): doğrulandı.
- pytest uyarısı tanımlandı (StarletteDeprecationWarning, httpx); henüz giderilmedi.
- Alternatif metin: 01'de 6, 02_eng'de 7 görsel.
- Hafta 6 hata 4 ve Hafta 7 m5, c4: açık.

Hafta 10 — Model

- Genel model ile ders geçmişli model, aynı test (2014J)
- Belirsizlik aralığı ve SHAP ile gerekçe
- Sisteme uyumlu özellik alt kümesi
- Sentetik okul geçmişi üreticisi (mock veriye dokunmadan)